

Tecnicatura Universitaria en Gestión y Análisis de Datos en
Organizaciones

Laboratorio de Métodos Cuantitativos · Facultad de Ciencias
Económicas · UBA

Análisis de costos e ingresos en e-commerce: estimación del presupuesto para equipar un gimnasio

Trabajo Práctico Grupal · 1^{er} Cuatrimestre 2026

Lautaro Caprile Damian Larrosa Juan Vallone

Buenos Aires, junio de 2026

Resumen

El presente trabajo analiza un dataset sintético de comercio electrónico global con aproximadamente un millón de registros correspondientes al período 2024–2026, con el objetivo de estimar el costo de equipar un gimnasio utilizando productos de las categorías *Sports* y *Health*. A partir de un proceso de filtrado, transformación y visualización de datos implementado en Python, se seleccionaron quince productos relevantes para la actividad física y se aplicaron funciones de costo e ingreso para determinar el ingreso total (IT), el costo total (CT), el beneficio y el punto de equilibrio por sub-categoría. Los resultados permiten identificar los segmentos de menor margen comercial como los más convenientes para una compra informada, y proporcionar una estimación fundamentada de la inversión necesaria para el equipamiento.

Palabras clave: análisis de datos, e-commerce, funciones de costo e ingreso, punto de equilibrio, equipamiento deportivo.

Índice

1	Introducción	4
2	Descripción del dataset	4
2.1	Fuente y descarga	4
2.2	Estructura	4
2.3	Calidad de los datos	5
3	Pregunta de investigación	5
4	Preparación de los datos	6
4.1	Filtros aplicados	6
4.2	Selección de productos	6
5	Análisis exploratorio y visualizaciones	6
5.1	Distribución de precios por sub-categoría (Boxplot)	6
5.2	Precio promedio por sub-categoría según marca (Barras apiladas) . . .	7
5.3	Evolución del precio promedio mensual por marca (Líneas superpuestas)	8
6	Aplicación de conceptos de la materia	9
6.1	Concepto elegido: funciones de costo e ingreso	9
6.1.1	Fundamentación	9
6.1.2	Marco teórico	10
6.1.3	Implementación en Python	10
6.1.4	Resultados	12
6.1.5	Interpretación	12
6.1.6	Supuestos y limitaciones	13
7	Conclusiones	13
	Nota sobre asistencia de inteligencia artificial	14

1. Introducción

La expansión del comercio electrónico ha generado grandes volúmenes de datos transaccionales que permiten, cuando se analizan correctamente, extraer información valiosa para la toma de decisiones económicas y comerciales. En este trabajo se utiliza el *Global E-Commerce Dataset (2024-2026)*, disponible públicamente en Kaggle [1], como fuente de datos para responder una pregunta de aplicación concreta: **¿cuánto costaría equipar un gimnasio adquiriendo productos de las categorías *Sports* y *Health* comercializados durante 2024 y 2025?**

La apertura o renovación de un gimnasio implica inversiones significativas en equipamiento. Disponer de una estimación basada en precios de un dataset sintético —en lugar de valores de referencia genéricos— permite dimensionar la inversión con mayor precisión y tomar decisiones de compra más informadas.

El análisis se estructura en tres etapas: (i) exploración y preparación del dataset; (ii) visualización de la distribución, comparación entre categorías y evolución temporal de precios; y (iii) aplicación de funciones de costo e ingreso para cuantificar la rentabilidad por sub-categoría y derivar el punto de equilibrio.

2. Descripción del dataset

2.1. Fuente y descarga

El dataset fue descargado directamente desde Kaggle mediante la biblioteca `kagglehub`, lo que garantiza la reproducibilidad del análisis:

```
1 import kagglehub
2 path = kagglehub.dataset_download(
3     "akrambelha/global-e-commerce-dataset-1m-records-20242026"
4 )
```

Listing 1: Descarga del dataset desde Kaggle

2.2. Estructura

El dataset contiene **62 columnas** y aproximadamente **un millón de registros**. Cada fila representa una transacción de comercio electrónico e incluye información sobre el cliente, el producto, los montos monetarios (precio, costo, ganancia, impuesto, descuento), el método de pago, el envío y métricas de comportamiento digital.

Las columnas de mayor relevancia para este análisis se detallan en la Tabla 1.

Tabla 1: Variables principales utilizadas en el análisis

Columna	Tipo	Descripción
order_id	Texto	Identificador único de la orden
order_year	Entero	Año de la transacción
order_month	Entero	Mes de la transacción
order_status	Texto	Estado de la orden (<i>Completed</i> , etc.)
category	Texto	Categoría del producto
sub_category	Texto	Sub-categoría del producto
brand	Texto	Marca del producto
product_name	Texto	Nombre del producto
unit_price_usd	Numérico	Precio unitario (USD)
quantity	Entero	Unidades adquiridas
total_price_usd	Numérico	Ingreso total de la orden (USD)
cost_usd	Numérico	Costo total de la orden (USD)
profit_usd	Numérico	Ganancia de la orden (USD)
profit_margin_percent	Numérico	Margen de ganancia (%)
discount_percent	Numérico	Descuento aplicado (%)
rating	Numérico	Calificación del producto (1–5)

2.3. Calidad de los datos

La exploración inicial no detectó registros duplicados. Los valores faltantes se concentran en variables opcionales —reseñas, cupones y motivos de devolución— cuya ausencia es consistente con la naturaleza de dichas variables: no toda compra genera una reseña ni está sujeta a una promoción. No se identificaron inconsistencias críticas que impidieran continuar con el análisis.

3. Pregunta de investigación

¿Cuál sería el costo estimado de equipar un gimnasio utilizando productos de las categorías *Sports* y *Health* comercializados durante los años 2024 y 2025?

La relevancia de esta pregunta reside en que la apertura de un gimnasio requiere decisiones de inversión concretas. Conocer el precio promedio de los principales insumos —con datos de transacciones simuladas— permite construir un presupuesto informado y evaluar qué sub-categorías ofrecen la mejor relación entre costo y beneficio.

4. Preparación de los datos

4.1. Filtros aplicados

Se aplicaron tres filtros sucesivos para acotar el dataset a las observaciones relevantes:

1. **Categoría:** se conservaron únicamente los registros de *Sports* y *Health* (399.971 registros).
2. **Estado:** se retuvieron solo las órdenes con estado **Completed**, descartando cancelaciones y devoluciones (279.912 registros).
3. **Período:** se limitó el análisis a los años 2024 y 2025, excluyendo datos parciales de 2026 (267.302 registros).

4.2. Selección de productos

Dentro del subconjunto filtrado se seleccionaron los quince productos que podrían formar parte del equipamiento o funcionamiento habitual de un gimnasio, descartando artículos no pertinentes para la pregunta de investigación. El dataset final contiene **222.743 registros**.

Los productos seleccionados son: Foam Roller, Gym Gloves, Resistance Bands Set, Swimming Goggles, Vitamin C Tablets, Massage Gun Deep Tissue, Protein Shaker Bottle, Fitness Smart Band, Water Bottle Insulated, Jump Rope Speed, Dumbbells Set Adjustable, Yoga Mat Non-Slip, Exercise Ball, Treadmill Folding y Tennis Balls Pack.

5. Análisis exploratorio y visualizaciones

5.1. Distribución de precios por sub-categoría (Boxplot)

La Figura 1 muestra la distribución del precio unitario (USD) dentro de cada sub-categoría presente en el dataset filtrado. La caja abarca el rango intercuartílico (Q1–Q3), la línea central indica la mediana y los puntos naranjas corresponden a valores atípicos (*outliers*).




Figura 1: Distribución de precios unitarios (USD) por sub-categoría. La caja representa el rango intercuartílico; la línea central, la mediana; los puntos naranjas, los valores atípicos.

Interpretación: La distribución de precios presenta un comportamiento relativamente homogéneo entre las distintas sub-categorías analizadas. Las categorías *Accessories*, *Gym Equipment*, *Outdoor* y *Sports Wear* exhiben medianas de precio superiores al resto, ubicándose en torno a los USD 130. Asimismo, la amplitud de los rangos intercuartílicos indica una elevada dispersión de precios dentro de cada sub-categoría, lo que sugiere la coexistencia de productos de diferentes niveles de calidad y posicionamiento comercial. La ausencia de diferencias extremas entre categorías permite inferir que el precio promedio no depende exclusivamente de la sub-categoría, sino también de otros factores como la marca o las características específicas de cada producto.

5.2. Precio promedio por sub-categoría según marca (Barras apiladas)

La Figura 2 muestra el precio promedio (USD) aportado por cada una de las cuatro marcas con mayor volumen de ventas, desagregado por sub-categoría. La altura total de cada barra representa el precio promedio acumulado considerando las marcas más vendidas.




Figura 2: Precio promedio (USD) por sub-categoría para las cuatro marcas con mayor volumen de ventas (top 4). Cada segmento de color corresponde a una marca.

Interpretación: Se observa que las cuatro marcas analizadas (Apple, GoPro, Philips y Xiaomi) presentan niveles de precios promedio similares dentro de cada sub-categoría. Sin embargo, las categorías *Sports Wear*, *Accessories*, *Gym Equipment* y *Outdoor* concentran los mayores valores promedio acumulados, mientras que *Fitness*, *Medical Devices*, *Personal Care* y *Supplements* registran niveles relativamente inferiores. Esto sugiere que los productos vinculados al equipamiento deportivo y la indumentaria representan segmentos de mayor valor económico dentro del conjunto analizado. Además, la similitud entre marcas indica que la categoría del producto parece tener una mayor influencia sobre el precio promedio que la marca en sí misma.

5.3. Evolución del precio promedio mensual por marca (Líneas superpuestas)

La Figura 3 muestra la evolución temporal del precio unitario promedio (USD) para cada una de las cuatro marcas con mayor volumen de ventas, desagregada por mes entre enero de 2024 y diciembre de 2025. La línea vertical punteada indica la transición entre años; la anotación con flecha doble señala el mes de mayor dispersión entre marcas.




Figura 3: Evolución mensual del precio unitario promedio (USD) para las cuatro marcas con mayor volumen de ventas. La línea vertical punteada marca el inicio de 2025; la anotación señala el mes de mayor dispersión entre marcas.

Interpretación: Los precios promedio de las principales marcas se mantuvieron relativamente estables durante el período analizado, con variaciones mensuales moderadas y sin tendencias marcadas de aumento o disminución. Esto sugiere que el costo de los productos necesarios para equipar un gimnasio no sufrió cambios significativos entre 2024 y 2025. Además, las diferencias de precio entre marcas suelen ser reducidas, por lo que la elección de una marca u otra tendría un impacto limitado sobre la inversión total estimada. En consecuencia, para este conjunto de productos, el costo de equipamiento parece estar más asociado al tipo de artículo adquirido que a fluctuaciones temporales o diferencias entre marcas.

6. Aplicación de conceptos de la materia

6.1. Concepto elegido: funciones de costo e ingreso

6.1.1. Fundamentación

El dataset provee directamente las variables `total_price_usd`, `cost_usd` y `profit_usd` a nivel de orden, lo que permite modelar las funciones de ingreso total, costo total y beneficio sin supuestos adicionales sobre la estructura de precios. Esta aplicación conecta con la pregunta de investigación: conocer la relación entre costos e ingresos por sub-categoría permite identificar en qué segmentos los márgenes son más altos y, por tanto, dónde existe mayor capacidad de negociación para quien equipa un gimnasio.

6.1.2. Marco teórico

En su forma discreta, las funciones de costo e ingreso se definen como:

$$IT = \sum_i p_i \cdot q_i = \sum_i \text{total_price_usd}_i \quad (1)$$

$$CT = \sum_i c_i \cdot q_i = \sum_i \text{cost_usd}_i \quad (2)$$

$$B = IT - CT = \sum_i \text{profit_usd}_i \quad (3)$$

$$\bar{p} = \frac{IT}{Q_{\text{total}}} \quad (\text{precio unitario promedio ponderado}) \quad (4)$$

$$\bar{c} = \frac{CT}{Q_{\text{total}}} \quad (\text{costo unitario promedio ponderado}) \quad (5)$$

$$Q^* = \frac{CF}{\bar{p} - \bar{c}} \quad (\text{punto de equilibrio en unidades}) \quad (6)$$

donde $Q_{\text{total}} = \sum_i \text{quantity}_i$ es la cantidad total de unidades vendidas en el período y CF denota el costo fijo estimado. Se utiliza la aproximación $CF \approx 0,20 \cdot CT$, supuesto habitual en análisis exploratorios de comercio electrónico donde los costos fijos operativos (plataforma, logística fija, almacenamiento) representan una fracción minoritaria del costo variable de producto.

6.1.3. Implementación en Python

Se implementó la función `analizar_costo_ingreso(df, grupo)`, documentada con *docstring*, que recibe el dataset filtrado y la columna de agrupación:

```

1 def analizar_costo_ingreso(df: pd.DataFrame,
2                             grupo: str = "sub_category") ->
3                                 pd.DataFrame:
4
5     """
6     Calcula IT, CT, beneficio y punto de equilibrio (Q*) por
7     grupo.
8
9     Definiciones:
10         IT = sum(total_price_usd)
11         CT = sum(cost_usd)
12         B  = IT - CT = sum(profit_usd)
13         p_bar = IT / Q_total (precio unitario promedio
14                             ponderado)

```

```

11         c_bar = CT / Q_total    (costo unitario promedio
12             ponderado)
13
14         Q*      = CF / (p_bar - c_bar),    con CF = 0.20 * CT
15
16     Parametros
17     -----
18
19     df      : DataFrame filtrado con columnas monetarias y
20         'grupo'.
21     grupo : columna de agrupacion (default "sub_category").
22
23     Retorna
24     -----
25
26     DataFrame con IT, CT, beneficio, margen_pct, precio_prom,
27     costo_prom, CF_estimado, Q_equilibrio.
28     """
29
30     resumen = (
31         df.groupby(grupo)
32         .agg(
33             ventas      = ("order_id",      "count"),
34             Q_total     = ("quantity",      "sum"),
35             IT          = ("total_price_usd", "sum"),
36             CT          = ("cost_usd",       "sum"),
37             beneficio   = ("profit_usd",     "sum"),
38         )
39         .round(2)
40     )
41
42     resumen["precio_prom"] = (resumen["IT"] /
43         resumen["Q_total"]).round(2)
44     resumen["costo_prom"]  = (resumen["CT"] /
45         resumen["Q_total"]).round(2)
46     resumen["margen_pct"]  = (
47         (resumen["beneficio"] / resumen["IT"]) * 100
48     ).round(2)
49     resumen["CF_estimado"] = (resumen["CT"] * 0.20).round(2)
50     margen_contrib         = resumen["precio_prom"] -
51         resumen["costo_prom"]
52     resumen["Q_equilibrio"] = (
53         resumen["CF_estimado"] / margen_contrib
54     ).replace([float("inf"), float("-inf")],
55         float("nan")).round(0)
56     return resumen.sort_values("beneficio", ascending=False)

```

Listing 2: Función de costo e ingreso con punto de equilibrio**6.1.4. Resultados**

La Figura 4 presenta el ingreso total, el costo total y el beneficio en millones de USD para cada sub-categoría, con el margen porcentual anotado sobre cada barra de beneficio.




Figura 4: Ingreso total (IT), costo total (CT) y beneficio (B) en millones de USD por sub-categoría. El porcentaje sobre cada barra violeta indica el margen B/IT .

La Tabla 2 resume los valores numéricos obtenidos para cada sub-categoría.

Tabla 2: Resultados de las funciones de costo e ingreso por sub-categoría

Sub-categoría	IT (M USD)	CT (M USD)	B (M USD)	Margen (%)	$\bar{p}$ (USD)	Q*
Accessories	10,95	6,57	4,38	39,96	120,80	27.232
Gym Equipment	10,83	6,49	4,34	40,06	121,30	26.722
Sports Wear	10,77	6,46	4,31	39,98	120,95	26.739
Outdoor	10,77	6,47	4,30	39,90	121,68	26.668
Fitness	7,49	4,49	3,00	39,99	96,96	23.193
Medical Devices	7,48	4,49	2,99	40,00	96,08	23.362
Personal Care	7,43	4,47	2,96	39,86	95,48	23.472
Supplements	7,42	4,47	2,96	39,86	96,14	23.306
Total	72,14	43,37	28,77	39,95	—	—

6.1.5. Interpretación

En todos los casos se verifica $IT > CT > 0$ y $B > 0$, resultado coherente con el filtro `order_status == "Completed"`: solo se consideran transacciones exitosas que

efectivamente generaron ingreso y cubrieron su costo. Esto es consistente con la definición microeconómica de beneficio como diferencia entre ingreso y costo.

El **margen de beneficio** por sub-categoría indica cuánto retiene el vendedor de cada unidad vendida. Desde la perspectiva del comprador, un margen alto señala mayor holgura entre el costo real y el precio de venta, lo que puede traducirse en mayor capacidad de negociación (descuentos, condiciones de pago, compras por volumen).

El **punto de equilibrio** Q^* indica las unidades mínimas que el vendedor necesita comercializar para cubrir los costos fijos estimados. Sub-categorías con Q^* bajo se sostienen con poco volumen y pueden ofrecer condiciones comerciales más flexibles para el comprador.

Implicancias para la pregunta de investigación: la sub-categoría con menor margen ofrece el menor *spread* entre costo y precio de venta, indicando precios más ajustados al costo real del producto. Para equipar un gimnasio con presupuesto acotado, priorizar las compras en los segmentos de menor margen maximiza el valor obtenido por cada dólar invertido.

6.1.6. Supuestos y limitaciones

- El dataset es sintético; los valores absolutos no reflejan un mercado real sino patrones generados algorítmicamente.
- El supuesto $CF = 0,20 \cdot CT$ es una aproximación exploratoria. Un análisis real requeriría información contable para separar costos fijos y variables.
- El punto de equilibrio asume $\bar{p}$ y $\bar{c}$ constantes, lo que puede no capturar economías de escala ni estacionalidad.

7. Conclusiones

El análisis realizado permite responder la pregunta de investigación con fundamento empírico. A partir de 222.743 transacciones completadas de productos de *Sports* y *Health* durante 2024 y 2025, se identificaron los segmentos de mayor y menor costo para equipar un gimnasio.

Los principales hallazgos son:

1. Las sub-categorías *Sports Wear*, *Accessories*, *Gym Equipment* y *Outdoor* concentran la inversión más significativa, con los precios unitarios promedios más altos y la mayor variabilidad de precios entre productos.

2. Los precios promedio por marca se mantuvieron relativamente estables durante el período 2024–2025, lo que sugiere que el momento de compra tiene impacto menor que la elección de sub-categoría y marca.
3. Las sub-categorías con menor margen de beneficio son las que ofrecen los precios más ajustados al costo real, y por tanto las más convenientes para una compra orientada a minimizar la inversión.
4. El punto de equilibrio estimado varía significativamente entre sub-categorías, lo que refleja estructuras de costo distintas y diferentes grados de dependencia del volumen de ventas.

Como limitación principal se reconoce el carácter sintético del dataset: los valores absolutos no deben interpretarse como precios de mercado reales, sino como patrones que ilustran la metodología aplicada. Un análisis equivalente sobre datos reales de proveedores o plataformas de e-commerce produciría estimaciones directamente accionables.

Nota sobre asistencia de inteligencia artificial

Durante la elaboración de este trabajo se utilizó inteligencia artificial generativa (Claude, Anthropic) como herramienta de asistencia para la generación de código Python, la redacción de *docstrings* y la estructura del presente informe. En todos los casos, el equipo revisó, evaluó y adaptó los resultados generados, asumiendo plena responsabilidad por el contenido final. El uso de IA se reporta en cumplimiento de los lineamientos académicos de la materia.

Referencias

- [1] Belha, A. (2024). *Global E-Commerce Dataset 1M Records (2024–2026)*. Kaggle. <https://www.kaggle.com/datasets/akrambelha/global-e-commerce-dataset-1m-records-20242026>